



Escola Politécnica de Enxeñaría de Ferrol

UNIVERSIDADE DA CORUÑA



Introducción al Aprendizaje Automático CURSO 2025/2026

Preparación de los datos y clasificación supervisada

M. U. en Ingeniería Industrial

AUTORES: ÁLVARO NAVEIRA CAAVEIRO
FRANCISCO RODRÍGUEZ GAVÍN

TUTORES: ALMA MARÍA MALLO CASDELO
FRANCISCO JAVIER BELLAS BOUZA

FECHA: MARZO DE 2026

Índice

1	Introducción	2
2	Descripción del conjunto de datos	2
2.1	Lectura de los datos	4
2.2	Transformación de los valores del conjunto de datos de texto a número	5
2.3	División del conjunto de datos en datos de entrada y salida	5
2.4	División del conjunto de datos en datos de entrenamiento y prueba	5
2.5	Balanceo de datos	6
2.5.1	Undersampling	6
2.5.2	Oversampling	6
2.6	Normalizado	6
2.7	Análisis de componentes principales (PCA)	8
3	Descripción de las pruebas realizadas	9
3.1	Algoritmo de clasificación por vecindad k-nn	9
3.2	Algoritmo de clasificación mediante métodos Kernel (SVM)	11
3.2.1	Estudio de los distintos casos	11
3.2.2	Conclusiones casos SVM	17
4	Bibliografía	18

1. Introducción

El presente trabajo tiene el objetivo de analizar el funcionamiento de dos técnicas de aprendizaje supervisado sobre un conjunto de datos etiquetados, de modo que se pueda realizar una caracterización objetiva de su funcionamiento en base a los resultados obtenidos. Para ello, primero se escogerá un conjunto de datos que sea válido para utilizarlo en tareas de clasificación, luego se le aplicarán las distintas técnicas de preprocesado que se consideren oportunas para finalmente, aplicar las técnicas de aprendizaje automático y realizar una comparación de sus resultados.

Para poder realizar este análisis, se implementará un programa en Python utilizando la librería *scikit-learn* para aplicar las técnicas de preprocesado de los datos y de aprendizaje automático. Además, se emplearán otras librerías como *Pandas* o *Numpy*, necesarias para la correcta lectura y manejo de los datos.

2. Descripción del conjunto de datos

La elección del conjunto de datos con el que se vaya a trabajar representa el primer paso de este proyecto. Como el objetivo es emplear conjuntos de datos reales, se han consultado distintas opciones en plataformas web como Kaggle o UCI y finalmente, se ha escogido una base de datos que permite clasificar las setas pertenecientes a la familia *Agaricus* y *Lepiota* como o venenosas o comestibles. [1]

El conjunto de datos seleccionado contiene un total de 8124 muestras. Para cada una de ellas se asocian un total de 22 características, cada una con distintas opciones. Aunque los autores de este conjunto de datos consideran distintas posibilidades dentro de cada característica, existen algunas opciones para las que no existe ninguna muestra, por lo que aparecen tachadas. A continuación se exponen cada una de las 22 variables que conforman la base de datos:

1. Forma del sombrero

b → Campana | c → Cónica | x → Convexa | f → Plana |
k → Con mamelón (protuberancia) | s → Deprimido

2. Superficie del sombrero

f → Fibroso | g → Con surcos | y → Escamoso | s → Liso

3. Color del sombrero

n → Marrón | b → Ante/Crema | c → Canela | g → Gris | r → Verde | p → Rosa |
u → Morado | e → Rojo | w → Blanco | y → Amarillo

4. Hematomas o manchas

t → Sí | f → No

5. Olor

a → Almendra | l → Anís | c → Creosota | y → Pescado | f → Fétido | m → Moho |
n → Inoloro | p → Picante | s → Especiado

6. Inserción de las láminas
a → Unidas | ~~d → Decurrentes~~ | f → Libres | ~~n → Escotadas~~
7. Espaciado de las láminas
c → Cerradas | w → Apiñadas | ~~d → Distantes~~
8. Tamaño de las láminas
b → Anchas | n → Estrechas
9. Color de las láminas
k → Negro | n → Marrón | b → Ante/Crema | h → Chocolate | g → Gris | r → Verde
o → Naranja | p → Rosa | u → Morado | e → Rojo | w → Blanco | y → Amarillo
10. Forma del tallo o pie
e → Ensanchado hacia la base | t → Se estrecha hacia la base
11. Raíz del tallo
b → Bulbosa | c → En forma de maza | ~~u → En forma de copa~~ | e → Cilíndrica |
~~z → Rizomorfos~~ | r → Con raíz | ? → No hay registro
12. Superficie del tallo por encima del anillo
f → Fibrosa | y → Escamosa | k → Sedosa | s → Lisa
13. Superficie del tallo por debajo del anillo
f → Fibrosa | y → Escamosa | k → Sedosa | s → Lisa
14. Color del tallo por encima del anillo
n → Marrón | b → Ante/Crema | c → Canela | g → Gris | o → Naranja | p → Rosa |
e → Rojo | w → Blanco | y → Amarillo
15. Color del tallo por debajo del anillo
n → Marrón | b → Ante/Crema | c → Canela | g → Gris | o → Naranja | p → Rosa |
e → Rojo | w → Blanco | y → Amarillo
16. Tipo de velo
p → Parcial | ~~u → Universal~~
17. Color del velo
n → Marrón | o → Naranja | w → Blanco | y → Amarillo
18. Número de anillos
n → Ninguno | o → Uno | t → Dos
19. Tipo de anillo
~~c → Cortina~~ | e → Sutil | f → Acampanado | l → Grande | n → No hay anillo |
p → Péndulo | ~~s → Envainado~~ | ~~z → En zona~~

20. Color de la esporada

k → Negro | n → Marrón | b → Ante/Crema | h → Chocolate | r → Verde |
o → Naranja | u → Morado | w → Blanco | y → Amarillo

21. Población

a → Abundante | c → Apiñada | n → Numerosa | s → Dispersa | v → Varias | y → Solitaria

22. Hábitat

g → Pastizales | l → Hojarasca | m → Praderas | p → Senderos | u → Urbano | w → Vertederos | d → Bosques

Es necesario aclarar que el archivo .csv que contiene el conjunto de datos, tiene definidas cada una de las opciones de cada atributo con una letra. En consecuencia, se ha expuesto el significado de cada letra, no obstante, el conjunto de datos que se utilizará a partir de ahora, tiene definidas cada una de las opciones de cada atributo con una palabra equivalente a su respectiva letra.

Por último, falta definir la característica objetivo que permite determinar si la seta que se está considerando en cada muestra es comestible o bien es venenosa. El objetivo del presente proyecto es establecer patrones utilizando algoritmos de clasificación, entre esta característica objetivo y las otras 22 características descriptivas, para ser capaz de determinar si una seta es venenosa o comestible si se conoce la forma de su sombrero, su color, su olor, el tamaño de las láminas, ...

2.1. Lectura de los datos

Una vez elegido el conjunto de datos, el siguiente paso es leer su contenido de forma correcta. Cada columna representa una característica y cada fila una muestra o seta que se ha analizado.

El conjunto de datos que se ha elegido tiene algunas muestras que no tienen definidas las 22 características, ya que falta alguna sobre la cual no hay información. Los autores de esta base de datos han identificado con el símbolo "?" aquellos datos que faltan, por lo que lo primero que se ha hecho es asociar al símbolo ? un valor nulo (utilizando la librería *Pandas*).

Luego, para comprobar la calidad del conjunto de datos elegido, se ha comprobado la cantidad de datos que faltan en cada una de las características, es decir, la cantidad de muestras para las que no hay información de cada atributo que se contempla. Como resultado, se observa que hay 2481 muestras para la que no hay información del atributo *Raíz del tallo*.

El hecho de que falten datos para alguno de los atributos dificulta que los algoritmos de clasificación encuentren patrones, por lo que conviene eliminar las muestras que no tengan toda la información. Como resultado, se reduce la cantidad de muestras, obteniendo un conjunto de datos compuesto por 5936 muestras que están caracterizadas por los 23 atributos.

Por otro lado, se observa que la columna *Poisonous* es la que define la característica o atributo objetivo que permite clasificar cada seta en comestible o venenosa. Realizando un recuento de cuantas de las setas analizadas son comestibles o venenosas, se obtiene que 3768 son aptas para el consumo y las 2168 restantes no lo son. Esto refleja que el 63,48 % de las muestras son comestibles, lo que implica que los datos no están balanceados. Esto representa

un problema para los algoritmos de clasificación, ya que provoca que el modelo determine de manera sesgada si una seta es apta o no para el consumo, tendiendo a considerarla como comestible. Este problema se abordará más adelante.

2.2. Transformación de los valores del conjunto de datos de texto a número

Un problema que presenta este conjunto de datos es que todos sus valores están en formato texto, lo que imposibilita realizar todo el estudio sobre este conjunto de datos. Para evitar esto, se pasan todos los valores presentes en el conjunto de datos de texto a número por lo que, pasará a ser este nuevo valor el que definirá las diferentes características de las setas permitiéndonos realizar el resto de preprocesado y las predicciones sobre este conjunto de datos sin problema.

2.3. División del conjunto de datos en datos de entrada y salida

Una vez que se tiene el conjunto de datos en donde para cada atributo se le asocia un número que define dicha característica, se procederá a definir cuales son los datos de entrada y salida. Para ello, se seleccionan las columnas que se utilizarán como entradas y se convierten en un array de *NumPy*, para poder utilizarlo con los algoritmos de clasificación de la librería *Scikit-learn* (con la columna que se utilizará como salida se hace lo mismo).

La columna "Poisonous" representa la salida, el valor que se quiere predecir, y el resto de columnas constituyen las entradas, los valores a partir de los cuales se realizará la predicción.

2.4. División del conjunto de datos en datos de entrenamiento y prueba

A la hora de entrenar un modelo, este necesita una cantidad de datos de *entrenamiento* (X_{train} e Y_{train}), los cuales estudiará y tratará de encontrar patrones para que, posteriormente, pueda realizar predicciones sobre unos *datos de prueba* (X_{test} e Y_{test}). Esto permitirá afinar la configuración modelo para luego emplearlo en la realidad.

Por lo tanto, este paso es clave para alcanzar el objetivo de definir un modelo que sea capaz de clasificar si una seta es comestible o venenosa, una vez se tiene la información de los 22 atributos que se están utilizando.

En la función "train_test_split" se podría añadir un valor ("test_size") que permite modificar la proporción de la división de los datos según se considere. Por defecto, esta función establece que el 75 % de los datos sea de entrenamiento y el 25 % restante sean datos de prueba.

Dado que el conjunto de datos que se está utilizando es bastante grande, se ha decidido que esta proporción es adecuada, obteniendo finalmente 4452 filas de datos de entrenamiento y 1484 filas de datos de prueba, a falta de terminar con el proceso de preprocesado.

Como se pide realizar 5 pruebas para 5 (X_{train} , Y_{train} , X_{test} e Y_{test}) distintos, lo que se va a hacer en este caso, será modificar el "random_state" para que, al darle diferentes valores, este nos genere los 5 (X_{train} , Y_{train} , X_{test} e Y_{test}) que buscamos y poder realizar de esta forma 5 pruebas para conjuntos de datos distintos.

2.5. Balanceo de datos

Tal y como se mencionó con anterioridad, la base de datos elegida para definir un modelo de clasificación está *desbalanceada*. Es decir, la cantidad de valores en la columna *poisonous* que se corresponden con setas comestibles y con setas venenosas no es la misma, siendo su diferencia igual a 1600 muestras, lo que supone que un 63 % de las setas estudiadas son comestibles y un 37 % son venenosas.

Esto puede influir en la capacidad del algoritmo para predecir correctamente la clase minoritaria (en este caso que una seta sea venenosa), ya que al estar menos representada este puede ignorarla, haciendo que el cálculo de la precisión del modelo no se asemeje completamente a la realidad.

Por lo tanto, para corregir esto, se utiliza la librería *Imbalanced-learn* para realizar el balanceo del conjunto de datos, el cual se puede realizar siguiendo dos filosofías distintas: eliminando muestras de la clase mayoritaria (*Undersampling*), o bien generando datos *sintéticos* de la clase minoritaria (*Oversampling*).

2.5.1. Undersampling

La técnica de *Undersampling* elimina muestras que se clasifican como setas comestibles, es decir, elimina las filas en cuya clase objetivo (que es *Poisonous*) se define una seta como comestible, que es la tipología de muestra mayoritaria. El objetivo es eliminar todas las muestras necesarias para que la cantidad de setas que se clasifican como comestibles y venenosas sea la misma para ambos casos.

Además, el algoritmo *NearMiss* no elimina las muestras de setas comestibles al azar. Calcula matemáticamente cuáles son las setas comestibles que están más cerca (o se parecen más) a las setas venenosas y se queda con esas, descartando las comestibles que son demasiado "obvias". De esta manera, el futuro modelo de clasificación aprenderá a distinguir los casos más difíciles.

2.5.2. Oversampling

La técnica de *Oversampling* genera muestras que se clasifican como setas venenosas, es decir, identifica cuál es el tipo de muestra minoritaria y añade filas que sean de ese tipo. El objetivo es generar de forma sintética todas las muestras necesarias para que la cantidad de setas que se clasifican como comestibles y venenosas sea la misma para ambos casos.

El algoritmo *SMOTE*, no se limita a copiar y pegar muestras de tipo seta venenosa, sino que genera nuevas muestras muy similares a las ya existentes, de forma que sus propiedades sean realistas para una seta venenosa. Además, definiendo la opción *random_state = 1*, se consigue que siempre genere las mismas muestras cada vez que se ejecuta el código (es lo que se conoce como una *semilla aleatoria*).

2.6. Normalizado

Una vez se ha realizado el balanceo de los datos, se procederá a realizar el escalado del conjunto de datos de entrenamiento y de prueba. Esto es fundamental para evitar que los algoritmos basados en distancias (como k-NN o SVM) tengan un sesgo y le den más peso a unas características que a otras simplemente por tener magnitudes mayores. Para nivelar

el rango de todas las variables, se pueden aplicar dos técnicas principales: la Normalización (mediante *MinMaxScaler*, que comprime los datos a un rango de 0 a 1) o la Estandarización (mediante *StandardScaler*, que centra los datos en una media de 0 y desviación estándar de 1).

El método *MinMaxScaler* viene representado por la siguiente fórmula:

$$xi = \frac{xi - \min(xi)}{\max(xi) - \min(xi)}$$

MinMaxScaler se caracteriza por poder transformar una característica para que quede, habitualmente entre un rango fijo de 0 y 1, permitiendo reescalar las características de un conjunto de datos y conservar la forma de la distribución: el porcentaje de variación entre un dato y otro no cambia. Esta técnica difiere un poco con respecto a *StandardScaler*, ya que al dato con mayor valor del rango se le asocia un 1 y al dato con menor valor se le asocia un 0.

El *StandardScaler* tiene como objetivo modificar todos los valores del conjunto de datos de tal forma que tengan un valor de media 0 y un valor de desviación típica de 1, tratando de aproximar los datos a la distribución normal estándar lo máximo posible. La fórmula que aplica es la siguiente:

$$xi = \frac{xi - \mu i}{\sigma i}$$

Realizando pruebas de exactitud y precisión, se pudo observar que ambos casos proporcionan resultados muy similares en los dos ámbitos. La distribución normal realiza el normalizado, como se pudo observar en la ecuación anterior, a partir de la media y la desviación típica, mientras que en el caso del *MinMaxScaler* se trabaja con los valores máximos y mínimos del conjunto de datos, para, categorizar todos los valores entre 0(valor mínimo) y 1(valor máximo). Esto nos lleva a observar que las diferencias relativas entre los valores ya normalizados cambian, tal y como se puede observar en las gráficas que se muestran a continuación.




Figura 1: Gráfica de variación de la densidad y el escalado de los datos

Se observa que al realizar el escalado de forma distinta, varían las distancias relativas entre componentes y las densidades de muestras en el conjunto. Además, también se puede observar que sí tiene un efecto claro sobre el conjunto de datos, donde se equiparan los resultados obtenidos mucho más, haciendo la muestra más homogénea.

Para los diferentes conjuntos de datos se decide emplear la técnica *StandardScaler*. Por otro lado, es necesario destacar que en aquellos conjuntos de datos donde se apliquen técnicas de balanceo de datos, el normalizado se aplicará de forma posterior a estas técnicas de balanceo, ya que el normalizado modifica las distancias entre los distintos datos provocando que las técnicas de balanceo no resulten tan efectivas sobre el conjunto de datos.

2.7. Análisis de componentes principales (PCA)

Una vez se ha llevado a cabo la normalización de los 3 conjuntos de datos (original, original con undersampling y original con oversampling), se procederá a realizar el PCA para buscar conjuntos de ejes de coordenadas en los que algunas de las dimensiones no sean necesarias para estos 3 conjuntos de datos.

Para ello se utilizará el algoritmo *PCA* implementando la librería *scikit-learn*. Inicialmente utilizaremos el algoritmo sin parámetros para analizar el porcentaje de varianza de todos los componentes utilizando *explained_variance_ratio_*, que devuelve una lista en este caso, con 22 elementos, donde cada elemento de la lista indica el porcentaje de variabilidad que representa ese componente. Además, sumando estos porcentajes de variabilidad se consigue saber la varianza acumulada correspondiente al número de componentes utilizado,s cumpliéndose siempre que la suma de todos los elementos de la lista dará 1 como resultado.

Conocidos estos porcentajes de varianza acumulada se pueden representar en una gráfica para poder ver claramente cual es la cantidad de componentes que se debería utilizar para hacer PCA.




Figura 2: Gráfica de varianza acumulada

Aquí se puede observar como a partir del decimoquinto componente la varianza acumulada tiene un valor muy cercano al 95 %, esto quiere decir que los datos que se van a perder se corresponden con el 5 % de los datos totales. Es por ello que se decide tomar un total de 15 componentes para realizar el cálculo del PCA, ya que con menos componentes las pérdidas de datos se consideran demasiado grandes todavía. Para confirmar que el *Projection loss* no es demasiado alto.

Obteniendo finalmente un valor de *Projection loss* del 5.07 % reduciendo las dimensiones del conjunto de 22 a 15, por lo que se considera aceptable.

3. Descripción de las pruebas realizadas

Una vez se han terminado de realizar todas las técnicas de preprocesado se tienen finalmente 6 posibles conjuntos a probar: Datos originales, Original + PCA, Undersampling sin PCA, Undersampling + PCA, Oversampling sin PCA, Oversampling + PCA. A estos conjuntos de datos se les aplicarán los algoritmos de clasificación que se han seleccionado, en este caso, *k-nn* y *SVM*.

3.1. Algoritmo de clasificación por vecindad k-nn

Este será el primer algoritmo de clasificación que se utilice. A la hora de determinar un dato perteneciente a una clase, se estima que aquellos datos pertenecientes a la misma clase se encontrarán próximos en el espacio de representación, siendo estos los “vecinos” representados en el código por la letra *k*.

Las pruebas que se realizarán serán para un rango de *k* de entre 5 y 100, tratando de buscar un valor que otorgue buenos resultados. Además, se intentará que este valor de *k* no sea ni muy bajo ni muy alto, ya que un valor de *k* alto da lugar a un modelo muy estable y poco sensible al ruido, pero puede perder detalles. En cambio, un valor de *k* bajo que proporciona un modelo flexible, que se adapta muy bien a variaciones y detalles, pero que es muy sensible al ruido.

Para realizar pruebas de una forma cómoda y comprobar cual es el mejor valor de *k*, se ha empleado un bucle *for* que permite obtener el valor de exactitud medio del modelo para cada valor de *k* de cada conjunto de datos, esto se debe a los 5 posibles valores de *X_train*, *Y_train*, *X_test* e *Y_test* que se han generado en la división de los datos para cada valor de *k*. De esta manera, se realiza el cálculo de exactitud media, desviación y tiempo de entrenamiento 5 veces para cada valor de *k*.

Con este código obtendremos de resultado final el valor de *k* para el cual la exactitud media y desviación son más favorables y, posteriormente, se le calculará tiempo que le lleva al modelo realizar las predicciones.

Por lo tanto nuestro mejor caso será para *k*=7 con una precisión del 100 % y un tiempo de entrenamiento de 5.38 ms. Este proceso se realizará de igual forma para el resto de casos que se realizarán a continuación:

En este caso se obtuvo que el mejor caso es para *k*=8 con una precisión del 100 % y un tiempo de entrenamiento de 7.2 ms. Ahora se realizarán las pruebas con este algoritmo para el caso con undersampling:

Tras lo observado en las gráficas y los datos obtenidos con el código, se puede determinar que el mejor caso es para *k*=7 con una exactitud de 0.985 y un tiempo de entrenamiento de 4.96 ms. Aplicando PCA para 15 componentes se obtendrán por lo tanto:

En este modelo el mejor caso es para *k*=6 donde se obtiene una precisión de 0.981 y un tiempo de entrenamiento de 6.03 ms. Una vez se han realizado los cálculos para el conjunto original y aplicando undersampling se realizará el mismo proceso para el conjunto de datos al que se le ha aplicado oversampling.

Donde se puede observar que el mejor caso es para $k=10$, donde conseguimos una precisión del 1.00 con un tiempo de entrenamiento de 6.44 ms. Terminaremos analizando y obteniendo las gráficas para el caso de oversampling con PCA.

Para este último caso, de oversampling con PCA, se ha vuelto a obtener una precisión del 1.00 para valores de k comprendidos entre 5 y 17 por lo que, guiándonos por el tiempo de entrenamiento, se toma que la mejor situación es para $k=8$ donde se obtiene un tiempo de entrenamiento de 6.93 ms, siendo este el mejor caso para oversampling con PCA.

Para poder ver de una forma más clara los resultados finales obtenidos por cada conjunto de datos, se decide realizar una tabla para representarlos:

Conjunto de datos	Exactitud del modelo	Tiempo de entrenamiento	Nº Vecinos
Original sin PCA	1.000	5.38 ms	$k=7$
Original con PCA	1.000	7.20 ms	$k=8$
Con undersampling sin PCA	0.985	4.96 ms	$k=7$
Con undersampling con PCA	0.981	6.03 ms	$k=6$
Con oversampling sin PCA	1.000	6.44 ms	$k=10$
Con oversampling con PCA	1.000	6.93 ms	$k=8$

Tabla 1: Resultados obtenidos para los conjuntos de datos

Observando esta tabla se puede ver con rapidez que la precisión del conjunto de datos es extremadamente alta, consiguiendo para aquellos casos con mayor cantidad de datos, es decir, el conjunto de datos original y el conjunto de datos con oversampling, que cuentan con una cantidad de filas muy superior al caso de undersampling, una precisión del 100 %.

Esto nos quiere decir que la cantidad de datos y el tipo de datos que se tienen para entrenar el modelo es un factor clave a la hora de conseguir precisiones altas con el mismo. El hecho de tener más de 4000 datos con 22 componentes categóricas que permitan predecir al modelo si la seta es comestible o venenosa, esto se considera un factor muy a tener en cuenta para explicar las precisiones tan altas que está consiguiendo el modelo.

Para la aplicación de PCA se puede observar como, al disminuir el número de dimensiones que se analizan de 22 a 15 disminuye la exactitud del modelo sutilmente, como se puede observar en los 2 casos con undersampling, pero no solo eso, también es notable un aumento en los tiempos de entrenamiento en relación con los casos donde no se aplica lo que nos lleva a una duda considerable con respecto a los beneficios de su aplicación.

Por lo tanto, si nos guiásemos únicamente por la tabla resumen, el mejor caso sería para el conjunto de datos original sin PCA. Esta afirmación tiene ciertos matices ya que este modelo podría tener algún tipo de sesgo a la hora de predecir debido al propio conjunto de datos. Esto se debe a que la correlación entre setas venenosas y comestibles no es 50/50 sino que se tienen 1600 casos adicionales de setas comestibles en comparación con las setas venenosas. Es por esto que finalmente se decide que el modelo óptimo es el que se corresponde con el conjunto de datos con oversampling sin PCA aplicando un valor de $k=10$, ya que se busca priorizar la exactitud del modelo frente a un tiempo de entrenamiento más bajo. Por último, no se muestran las matrices de confusión en estos casos ya que para una precisión de 1.00 no son muy representativas, no hay ningún error que se pueda observar.

3.2. Algoritmo de clasificación mediante métodos Kernel (SVM)

Ahora se realizarán las pruebas sobre los distintos conjuntos de datos con el algoritmo SVM. El algoritmo SVM se caracteriza por minimizar el riesgo estructural para reducir la posibilidad de cometer errores futuros. Dentro de este algoritmo, este se puede modificar y variar de dos formas, cambiando el valor de C o cambiando el tipo de kernel.

Para realizar el estudio de este algoritmo, se llevará a cabo una prueba que consistirá en cambiar el valor de C en el rango de 1-10, para ver de que manera varían los resultados obtenidos.

El parámetro C es el que controla el peso de los términos de error, es decir, indica cuanto castiga el SVM los errores de clasificación. Esto quiere decir que con un valor de C alto, el modelo será más sensible al ruido y tendrá una tendencia a sobreajustar, lo que lo hace menos fiable si se aplicase a otros conjuntos de datos. Sin embargo para un valor de C bajo el modelo tenderá más a ignorar el ruido presente en el conjunto, pero tiene una mayor tendencia a no capturar bien estructuras complejas.

Por otro lado, en lo referente al kernel aplicado, un kernel lineal asume que los datos son linealmente separables y busca trazar un hiperplano óptimo que maximice el margen entre ambas clases (setas comestibles y venenosas). La elección de este kernel no solo simplifica la complejidad matemática del modelo, reduciendo notablemente los tiempos de ejecución frente a kernels no lineales, sino que también resulta especialmente adecuado al trabajar con espacios de alta dimensionalidad. Esto cobra especial relevancia en nuestro estudio al analizar el impacto de técnicas como el Análisis de Componentes Principales (PCA), donde buscamos observar si la proyección lineal de las características facilita la labor del clasificador.

Como consecuencia de todos los parámetros que se quieren evaluar se diseñó un código muy similar al aplicado para el algoritmo K-NN, solo que en este caso el bucle se realizará para unos valores de C de 1.0 hasta 10.0, y se sustituirán aquellas funciones propias del k-nn por funciones aplicadas al algoritmo SVM. El objetivo será, de nuevo, observar el valor medio de la exactitud para cada valor de C y su desviación para determinar cual es el valor de C más óptimo para cada caso. Finalmente, se concluirá qué modelo utilizando SVM es mejor.

3.2.1. Estudio de los distintos casos

Con el objetivo de obtener el mejor modelo basado en el algoritmo de clasificación SVM, se han modificado los datos de entrenamiento que utiliza para establecer patrones entre el atributo objetivo y las demás características que definen si una seta es comestible o venenosa. El objetivo es definir cuáles son las técnicas de preprocesado idóneas para que la precisión del modelo sea la mayor posible.

De esta manera, al igual que se hizo con el algoritmo KNN se definen 6 tipologías de datos de entrada, donde cada una de ellas tiene aplicadas unas técnicas de preprocesado diferentes. Además, para cada tipología, se generarán 5 conjuntos de datos diferentes, en donde lo que cambia es el conjunto de datos que define los datos de entrenamiento (X_{train} , Y_{train}) y datos de prueba (X_{test} , Y_{test}). Tal y como se explicó con anterioridad, todo esto permite elegir el valor de C idóneo para cada caso.

Caso 1: Datos originales

El primer caso evaluado es el más sencillo de todos, ya que consiste en tomar los datos originales, aplicarles una normalización estándar y entrenar el algoritmo SVM para 10 valores distintos de C. Una vez concluido el entrenamiento, el resultado de la predicción se puede ver en la siguiente tabla, en la que se muestran los 5 valores de C que provocan que el modelo alcance una mayor exactitud y menor desviación:

Valor de C	Exactitud media	Desviación
10.0	1.0	0.0
9.0	0.9982479784366577	0.0026133045053457113
8.0	0.9979784366576819	0.0024850524143646426
7.0	0.9975741239892184	0.002279182550577849
6.0	0.9975741239892184	0.002279182550577849

Tabla 2: Mayores precisiones para el conjunto de datos con los datos originales

Se puede observar que la precisión del modelo aumenta a medida que el valor de C se hace más grande, llegando a tener una exactitud media del 100 % para los 5 conjuntos de datos analizados, y una desviación estándar nula en el caso de $C = 10$.

Caso 2: PCA

En el segundo caso se ha considerado una normalización estándar y un análisis de componentes principales (PCA), con el objetivo de reducir las dimensiones de la base de datos que tiene que analizar el algoritmo. Se aplicó un PCA de 15 componentes, mostrándose resultados en la siguiente tabla:

Valor de C	Exactitud media	Desviación
1.0	0.9269541778975741	0.004441309178782765
2.0	0.9269541778975741	0.004145163476881295
3.0	0.9268194070080863	0.004123196372177428
5.0	0.9268194070080863	0.004123196372177428
7.0	0.9268194070080863	0.004123196372177428

Tabla 3: Mayores precisiones para el conjunto de datos original con PCA

Se observa que al reducir las componentes del sistema se ha perdido información, lo que ha provocado que el modelo tenga una menor exactitud. Además, se observa que a medida que C se incrementa el modelo se vuelve menos preciso, lo que puede indicar un ligero sobreentrenamiento, ya que la diferencia de precisión es muy baja.

El valor de C con mayor precisión es $C = 1$, con el que se obtiene un modelo capaz de predecir con una exactitud media del 92,69 % si una seta es comestible o bien es venenosa. No obstante, dicho valor de C es el que tiene una mayor desviación media también.

En este caso, si es de interés mostrar la matriz de confusión, ya que la exactitud ya no es total. En la siguiente imagen se observa que para un conjunto de datos determinado (uno de los cinco evaluados), de todas las muestras evaluadas (1484), existen 105 que el algoritmo no clasifica bien. Son especialmente relevantes las 47 setas venenosas que determina como

comestibles, ya que es el caso que se quiere evitar a toda costa.




Figura 3: Matriz de confusión para el conjunto de datos con PCA

Caso 3: Undersampling

En el tercer caso, se ha realizado un balanceo del conjunto de datos utilizando la técnica de *Undersampling* y luego una normalización estándar. Esto permite balancear los datos originales, de manera que el algoritmo aprenda sobre un conjunto de datos en el que hay la misma cantidad de setas comestibles y venenosas. Los resultados se muestran en la siguiente tabla:

Valor de C	Exactitud media	Desviación
10.0	0.9867924528301886	0.0025783189312276016
9.0	0.9867924528301886	0.0025783189312276016
8.0	0.9867924528301886	0.0025783189312276016
7.0	0.9867924528301886	0.0025783189312276016
6.0	0.9867924528301886	0.0025783189312276016

Tabla 4: Mayores precisiones para el conjunto de datos con Undersampling

En la tabla se puede ver que para los cinco valores mostrados el modelo tiene de media la misma precisión y desviación estándar. Esto resulta en que cualquiera valor de C de los que se han evaluado, excepto para el valor de C = 1, se pueden elegir como parámetro del algoritmo.

Finalmente, se escogió un valor de $C = 2$ para el cual el modelo tiene una precisión del 98,68 % y una desviación estándar de 0,258 %. La matriz de confusión del modelo para dicho valor de C es la siguiente:




Figura 4: Matriz de confusión para el conjunto de datos con Undersampling

Se puede observar que de las 1484 muestras analizadas en solo 24 el modelo falla en su predicción, al considerarlas venenosas cuando en realidad son comestibles. Este fallo de predicción no es muy grave, ya que se sitúa del lado de la seguridad.

Caso 4: Undersampling + PCA

En el cuarto caso se ha llevado un balanceo de datos aplicando la técnica de *Undersampling*, luego se ha realizado una normalización estándar para, finalmente, ejecutar un PCA de 15 componentes. De esta manera, el algoritmo ha trabajado con un conjunto de datos balanceado y cuyas dimensiones son reducidas en comparación con la base de datos original. Los resultados se muestran en la siguiente tabla:

Valor de C	Exactitud media	Desviación
6.0	0.8289757412398921	0.017255937539266
7.0	0.8265498652291106	0.014686935553450431
8.0	0.8252021563342318	0.015639231191782912
5.0	0.8242587601078167	0.02494317544235126
4.0	0.8242587601078167	0.029976754216091

Tabla 5: Mayores precisiones para el conjunto de datos con Undersampling y PCA

Se puede observar que en esta ocasión que la precisión del modelo se incrementa junto con el valor de C. En cambio, la desviación disminuye a medida que C se hace más grande. Para valores de C mayores que $C = 6$, la exactitud de la previsión del modelo disminuye, lo que indica que puede existir un ligero sobreentrenamiento.

Por lo tanto, el valor de C escogido como el mejor para este caso es $C = 6$, dando como resultado un modelo que genera la previsión menos veraz de todos los modelos analizados con

el algoritmo SVM, siendo esta del 82,89 %.

La matriz de confusión obtenida para dicho valor de C es la siguiente:




Figura 5: Matriz de confusión para el conjunto de datos con Undersampling y PCA

Se puede observar que de todas las setas analizadas, existen 21 que está clasificando como comestibles cuando en realidad son venenosas. Este es un valor más bajo que el del modelo definido en el Caso 2, sin embargo, representa una característica muy negativa del presente modelo.

Caso 5: Oversampling

En el quinto caso se ha considerado un balanceo del conjunto de datos empleando la técnica de *Oversampling* y luego una normalización estándar. De esta manera, el algoritmo trabaja con un conjunto balanceado de datos y con una mayor cantidad de muestras en comparación con las bases de datos de los casos 3 y 4. Los resultados se muestran en la siguiente tabla:

Valor de C	Exactitud media	Desviación
10.0	1.0	0.0
9.0	0.9991913746630727	0.0016172506738544533
8.0	0.9991913746630727	0.0016172506738544533
7.0	0.9979784366576819	0.0013477088948787186
6.0	0.9977088948787062	0.0010085329883487918

Tabla 6: Mayores precisiones para el conjunto de datos con Oversampling

En la tabla se puede ver que el presente modelo se comporta de manera similar al visto en el Caso 1, ya que la exactitud de la previsión se incrementa junto con el valor de C. Para $C = 10$ se obtiene una precisión del 100 % y una desviación nula, por lo que este es el valor

elegido como el idóneo para este modelo.

Caso 6: Oversampling + PCA

En el sexto y último modelo considerado, se ha realizado un balanceo del conjunto de datos empleando la técnica de *Oversampling*, luego una normalización estándar y finalmente, un PCA de 15 componentes. Los resultados se muestran en la siguiente tabla:

Valor de C	Exactitud media	Desviación
10.0	0.930188679245283	0.007087975090191227
9.0	0.930188679245283	0.007087975090191227
8.0	0.930188679245283	0.007087975090191227
7.0	0.930188679245283	0.007087975090191227
6.0	0.930188679245283	0.007087975090191227

Tabla 7: Mayores precisiones para el conjunto de datos con Oversampling y PCA

Al igual que ocurriría con el modelo visto en el Caso 3, la exactitud de la predicción no cambia con el valor de C a partir de $C = 5$, por lo que este es el valor escogido como parámetro del algoritmo.

Como resultado, para dicho valor de C, el modelo tiene una precisión del 93,02 % y una desviación estándar del 0,709 %, obteniéndose para un conjunto de datos determinado la siguiente matriz de confusión:




Figura 6: Matriz de confusión para el conjunto de datos con Oversampling y PCA

En dicha matriz de confusión se aprecia que el modelo predice 32 muestras como comestibles cuando no lo son, lo que presenta un defecto significativo en comparación con el resto de modelos analizados.

3.2.2. Conclusiones casos SVM

Una vez analizados todos los casos planteados, se presenta a continuación una tabla comparativa de la exactitud y de los tiempos de ejecución de la predicción del modelo (en milisegundos), para cada uno de los valores con los que se obtiene un mejor modelo C para cada caso.

Casos de análisis	C	Exactitud	Tiempo ejecución
Caso 1: Datos originales	10	1.0	253.859281539917
Caso 2: Datos originales con PCA	1	0.9292452830188679	458.9681625366211
Caso 3: Datos undersampling	2	0.9838274932614556	63.28630447387695
Caso 4: Datos undersampling con PCA	6	0.8241239892183289	502.55680084228516
Caso 5: Datos oversampling	10	1.0	521.1420059204102
Caso 6: Datos oversampling con PCA	5	0.9346361185983828	2065.0877952575684

Tabla 8: Mejores casos de cada conjunto de datos

Se puede observar que desde el punto de vista de la exactitud, los modelos desarrollados en los casos 1 y 5 son los que presentan una mayor exactitud, aunque difieren en cuanto al tiempo de ejecución.

Como el *Caso 1* tiene la mejor precisión y su tiempo de ejecución es la mitad respecto del *Caso 5*, se considera que este es el mejor modelo utilizando el algoritmo SVM.

Por último, mencionar que el resto de casos tienen el gran defecto de que consideran algunas seta como comestibles cuando estas son venenosas, excepto el *Caso 3*, el cual tiene una precisión muy buena del 98,38 % y su tiempo de ejecución es el menor de todos. Además, para este último caso, se observó en su respectiva matriz de confusión que los fallos de predicción se sitúan del lado de la seguridad, por lo que este constituye también un muy buen modelo de predicción.

4. Bibliografía

- [1] Mushroom dataset. url = <https://archive.ics.uci.edu/dataset/73/mushroom>. Consultado: 22-03-2026.